

Hidden Markov Models (HMM)

By PhD. Josafá Pontes

Introducción

- Un Hidden Markov Model (HMM) es un modelo estadístico probabilístico.
- Tiene estados ocultos y observaciones visibles.
- Los estados ocultos siguen una Cadena de Markov.
- Las observaciones dependen probabilísticamente de los estados ocultos.

Aplicaciones

- Reconocimiento automático de voz.
- Procesamiento de lenguaje natural.
- Bioinformática.
- Predicción climática.
- Reconocimiento de escritura.

Formalismo HMM (1)

- $HMM = \{S, O, \pi, A, B\}$
- S: estados ocultos.
- O: observaciones.
- π : probabilidades iniciales.
- A: matriz de transición.
- B: matriz de emisión.

Formalismo HMM (2)

- En Hidden Markov Models, el símbolo:

$$\lambda=(A,B,\pi)$$

representa el modelo completo del HMM,
donde:

- A: matriz de transición entre estados ocultos.
- B: matriz de probabilidades de emisión.
- π : vector de probabilidades iniciales.
- $P(O|\lambda)$ es la probabilidad de observar la secuencia O dado el modelo HMM λ .

Ejemplo

Si tenemos:

- $\lambda=(A,B,\pi)$ con:
- $A=[[0.7, 0.3], [0.4, 0.6]]$
- $B=[[0.5, 0.4, 0.1], [0.1, 0.3, 0.6]]$
- $\pi=[0.6,0.4]$
- $O=(\text{Normal}, \text{Cold}, \text{Dizzy})$

Entonces, $P(O \mid \lambda)$ es la probabilidad de que ese modelo HMM haya generado esa secuencia observable.

Suposición de Markov

- El siguiente estado depende únicamente del estado actual.
- $P(X_t \mid X_{t-1}, \dots, X_0) = P(X_t \mid X_{t-1})$


Problemas Fundamentales

- Evaluación: calcular $P(O \mid \lambda)$.
- Decodificación: hallar la secuencia oculta más probable mediante algoritmo de Viterbi.
- Aprendizaje: estimar parámetros del modelo.

Algoritmo de Viterbi

- Permite encontrar la secuencia de estados ocultos más probable.
- Usa programación dinámica.
- Construye un Trellis de probabilidades.

Trellis for the hidden states $\in Q$ given a sequence of observations $O = \{o_0, o_1, o_2, o_3, o_4\}$



~ 3

~ 4

Algoritmo de Viterbi

Input:

- O = sequence of observations
- A = transition probability matrix
- B = emission probability matrix
- π = initial state probabilities
- Output:
Most probable hidden state sequence

Algoritmo de Viterbi

```
function VITERBI( $O, S, \Pi, Y, A, B$ ) :  $X$ 
  for each state  $i = 1, 2, \dots, K$  do
     $T_1[i, 1] \leftarrow \pi_i \cdot B_{iy_1}$ 
     $T_2[i, 1] \leftarrow 0$ 
  end for
  for each observation  $j = 2, 3, \dots, T$  do
    for each state  $i = 1, 2, \dots, K$  do
       $T_1[i, j] \leftarrow \max_k (T_1[k, j-1] \cdot A_{ki} \cdot B_{iy_j})$ 
       $T_2[i, j] \leftarrow \arg \max_k (T_1[k, j-1] \cdot A_{ki} \cdot B_{iy_j})$ 
    end for
  end for
   $z_T \leftarrow \arg \max_k (T_1[k, T])$ 
   $x_T \leftarrow s_{z_T}$ 
  for  $j = T, T-1, \dots, 2$  do
     $z_{j-1} \leftarrow T_2[z_j, j]$ 
     $x_{j-1} \leftarrow s_{z_{j-1}}$ 
  end for
  return  $X$ 
end function
```

Ejemplo Médico

- Estados ocultos: Healthy (H) y Fever (F).
- Observaciones: Normal, Cold, Dizzy.
- Secuencia observada: Normal $\rightarrow$ Cold $\rightarrow$ Dizzy.

Ejemplo Médico

Consider a village where all villagers are either healthy or have a fever and only the village doctor can determine whether each has a fever. The doctor diagnoses fever by asking patients how they feel. The villagers may only answer that they feel normal, dizzy, or cold.


The doctor believes that the health condition of his patients operates as a discrete [Markov chain](#). There are two states, "Healthy" and "Fever", but the doctor cannot observe them directly; they are hidden from him. On each day, there is a certain chance that the patient will tell the doctor he is "normal", "cold", or "dizzy", depending on their health condition.

The observations (normal, cold, dizzy) along with a hidden state (healthy, fever) form a hidden Markov model (HMM).

The patient visits three days in a row and the doctor discovers that on the first day he feels **normal**, on the second day he feels **cold**, on the third day he feels **dizzy**.

The doctor has a question: what is the most likely sequence of health conditions of the patient that would explain these observations?

Let's use Viterbi algorithm to answer to this question.



Parámetros del Modelo

- $\pi = [0.6, 0.4]$
- $A = [[0.7, 0.3], [0.4, 0.6]]$
- $B(H) = [0.5, 0.4, 0.1]$
- $B(F) = [0.1, 0.3, 0.6]$

Inicialización $t=0$

- Observación: Normal
- Healthy: $0.6 \times 0.5 = 0.3$
- Fever: $0.4 \times 0.1 = 0.04$
- Estado más probable: Healthy

Recursión $t=1$

- Observación: Cold
- Healthy: $\max(0.3 \times 0.7, 0.04 \times 0.4) \times 0.4 = 0.084$
- Fever: $\max(0.3 \times 0.3, 0.04 \times 0.6) \times 0.3 = 0.027$


Recursión $t=2$

- Observación: Dizzy
- Healthy: $\max(0.084 \times 0.7, 0.027 \times 0.4) \times 0.1 = 0.00588$
- Fever: $\max(0.084 \times 0.3, 0.027 \times 0.6) \times 0.6 = 0.01512$

Resultado Viterbi

- Secuencia más probable:
- Healthy $\rightarrow$ Healthy $\rightarrow$ Fever
- $P(O \mid \lambda) = 0.01512$

Resumen del cálculo en la Trellis



Ejemplo 2

Suponga que ha entrenado un Modelo Oculto de Markov (HMM) y obtiene el modelo: $\lambda = (A, B, \pi)$ donde:

$A =$

0.7 0.3

0.4 0.6

$B =$

0.1 0.4 0.5

0.7 0.2 0.1

$\pi = [0.0 \quad 1.0]$

Los estados ocultos corresponden a: H y C, respectivamente. La matriz de emisión B sigue el orden: M, S y L. Dada la secuencia de observaciones S, M, y L y el modelo $\lambda=(A,B,\pi)$, calcular:

a) La probabilidad de la secuencia de observaciones dada el modelo:

$P(O \mid \lambda)$

b) La secuencia más probable de estados ocultos correspondiente a las observaciones O.

Parámetros del Modelo

- $\pi = [0.0, 1.0]$
- $A = [[0.7, 0.3], [0.4, 0.6]]$
- $B(H) = [0.1, 0.4, 0.5]$
- $B(F) = [0.7, 0.2, 0.1]$

Inicialización $t=0$

- Observación: S
- H: $0.0 \times 0.4 = 0$
- C: $1.0 \times 0.2 = 0.2$
- Estado más probable: C

Recursión $t=1$

- Observación: M
- H: $\max(0 \times 0.7 = 0, 0.2 \times 0.4 = 0.8) \times 0.1 = 0.008$
- C: $\max(0 \times 0.3 = 0, 0.2 \times 0.6 = 0.12) \times 0.7 = 0.084$

Recursión $t=2$

- Observación: L
- H: $\max(0.008 \times 0.7 = 0.0056, 0.084 \times 0.4 = 0.0336) \times 0.5 = 0.0168$
- C: $\max(0.008 \times 0.3 = 0.0024, 0.084 \times 0.6 = 0.0504) \times 0.1 = 0.0504 \times 0.1 = 0.00504$

Resultado Viterbi

- Secuencia más probable:
- $C \rightarrow C \rightarrow H$
- $P(O \mid \lambda) = 0.0168$

Conclusiones

- Los HMM modelan procesos secuenciales probabilísticos.
- Viterbi permite inferir estados ocultos.
- Son fundamentales en ASR y NLP.