
Inteligencia Artificial y Aprendizaje Automático

Proyecto Final

Predicción del comportamiento del fantasma con un modelo LSTM, a partir de la estructura y la liquidez del motor de charting.

7 649

muestras de entrenamiento
(abril-junio)

2 391

muestras de prueba
(1-24 de julio)

86

variables de entrada
normalizadas

4

salidas numéricas
 $y_3 \cdot y_5 \cdot y_{10} \cdot y_{15}$

Cuatro salidas, una por horizonte

Cada vez que el fantasma aparece o se reubica se toma una muestra. El modelo predice cuántos rastros dejará hacia adelante en cuatro horizontes distintos.

DEFINICIÓN DE LAS SALIDAS

y3	rastros en los próximos 3 minutos
y5	rastros en los próximos 5 minutos
y10	rastros en los próximos 10 minutos
y15	rastros en los próximos 15 minutos

ENTRADA DEL MODELO

Una ventana de 5 muestras consecutivas, cada una con 86 variables calculadas en la vela siguiente al evento: distancias en PIPs a niveles de liquidez y estructura en 1m, 10m y 1h.

El disparo es el evento del fantasma

- 01

Detección del evento

Se recorre el histórico 1m en modo Replay y se registra cada aparición o reubicación del fantasma provisional.
- 02

Contexto causal

Las variables se calculan mirando solo hacia atrás, con la información disponible hasta la vela siguiente al evento. Nada mira el futuro.
- 03

Etiquetado automático

Las salidas y3/y5/y10/y15 se obtienen contando los rastros que efectivamente aparecen después del evento.

VOLUMEN DEL DATASET	
Train	7 649 muestras · abr-jun (88 736 velas)
Test	2 391 muestras · 1-24 jul (24 179 velas)
Secuencias	7 645 train / 2 387 test (ventana 5)

El comportamiento del fantasma replica el indicador implementado en el motor de charting.

Del CSV al modelo

1 · EXTRACCIÓN

Script sin interfaz gráfica recorre el CSV en Replay y, en cada evento del fantasma, guarda una fila con las 86 variables y las 4 salidas futuras.

7 649 filas train · 2 391 test

2 · NORMALIZACIÓN

Estandarización z-score con media y desviación calculadas solo con train; el test se transforma con los mismos parámetros.

Tiempo y metadatos no entrenan

3 · ENTRENAMIENTO

LSTM de una capa (48 unidades, dropout 0.2), ventana de 5 muestras, 4 salidas, error cuadrático medio, optimizador Adam y parada temprana con validación.

Grid de 8 configuraciones (~8 min) · pesos guardados en disco

Error en el conteo de rastros

REGRESIÓN · N = 2 387 SECUENCIAS DE TEST

Salida	MAE	RMSE
y3 · 3 min	0.82	1.01
y5 · 5 min	1.15	1.41
y10 · 10 min	1.75	2.15
y15 · 15 min	2.24	2.77

En la ventana corta el modelo se equivoca en menos de un rastro en promedio (MAE 0.82 en y3). El error crece con el horizonte, de forma esperada: a 15 minutos hay más rastros posibles y más incertidumbre. El error medio de las cuatro ventanas es 1.49 rastros, un 17% menos que la primera versión entrenada del modelo.

¿Aparece al menos un rastro?

POSITIVO = ≥1 RASTRO EN LA VENTANA · N = 2 387

Salida	Accuracy	Precision	Recall	F1
y3	0.71	0.69	0.98	0.81
y5	0.75	0.75	0.99	0.85
y10	0.81	0.81	0.99	0.89
y15	0.83	0.84	0.99	0.91

El modelo casi no se pierde una ventana con actividad: detecta 98-99% de los casos con al menos un rastro (recall). Cuando anuncia actividad a 10-15 minutos acierta 81-84% de las veces (precision); el F1 promedio de las cuatro ventanas es 0.87.

Detalle por ventana

POSITIVO = ≥1 RASTRO · N = 2 387 POR FILA

Salida	TP	FP	TN	FN
y3	1 513	668	174	32
y5	1 675	563	126	23
y10	1 862	427	81	17
y15	1 939	380	46	22

LECTURA

TP predijo rastro y sí hubo

FP predijo rastro y no hubo

TN predijo que no y no hubo

FN predijo que no y sí hubo

Casi no deja pasar actividad real: solo 17-32 falsos negativos por ventana, de 1 545-1 961 casos con rastro.

Cargar el modelo y comparar

El programa carga los pesos entrenados (no reentrena), arma las ventanas de 5 muestras sobre el test ya normalizado e imprime el conteo real contra la predicción para varios puntos de julio.

```
# entorno: WSL Fedora - raiz del proyecto

cd /mnt/c/Users/bryan/ia/proyecto_iaaa/Proyecto/ProyectoIAAA
perl -I. scripts/demo_fantasma_predict.pl --n 8
```

PASO 1

Carga el test normalizado y los pesos .params

PASO 2

Construye ventanas de 5 muestras consecutivas

PASO 3

Imprime TRUE vs PRED para y3 · y5 · y10 · y15

Qué queda demostrado

- 01

El disparo es correcto

Cada muestra corresponde a un evento real del fantasma, con contexto estrictamente causal.
- 02

El pipeline es reproducible

Extracción, normalización, entrenamiento y evaluación quedan como scripts ejecutables.
- 03

El modelo predice en vivo

Carga los pesos y compara contra datos que nunca vio en entrenamiento.

RESUMEN	
Dataset train/test	7 649 / 2 391
Variables	86
MAE prom · 4 ventanas	1 . 49
F1 prom · binario	0 . 87